

The background is a light blue gradient with various medical icons: a heart, a pulse line, a blood drop, a test tube with red liquid, a syringe, a bandage, and several pills. There are also small red plus signs scattered throughout.

ASISTENTE CLÍNICO AI

PARA LA PREDICCIÓN DE REINGRESOS
HOSPITALARIOS EN PACIENTES CON
DIABETES

CARLOS FORT DUART

ARQUITECTURA PIPELINE

- Carga de datos de pacientes diabéticos
- Preprocesamiento
 - Limpieza de valores nulos
 - Codificación de variables categóricas
 - Creación de variables derivadas (feature engineering)
- Selección de variables
- Entrenamiento del modelo
 - División en conjuntos de entrenamiento y prueba
 - Ajuste y validación del modelo
- Evaluación
 - Accuracy
 - Precision
 - Recall
 - F1-Score
 - ROC-AUC
- Explicabilidad (SHAP)
- Despliegue web (Streamlit)



ASPECTOS TÉCNICOS

1. Construcción de la variable objetivo

- Problema de clasificación binaria
 - 1 = paciente con reingreso hospitalario
 - 0 = paciente sin reingreso
- Objetivo: estimar la probabilidad de reingreso tras el alta

2. División de datos

- 70% Training Set → utilizado para el entrenamiento y aprendizaje del modelo
- 15% Validation Set → optimización de hiperparámetros mediante Optuna
- 15% Test Set → evaluación final del rendimiento

Objetivos: evitar el sobreajuste, optimizar adecuadamente el modelo y obtener una estimación más realista de su capacidad de generalización

3. Modelo seleccionado: CatBoost Classifier


- Maneja variables categóricas de forma nativa.
- Requiere menos preprocesamiento.
- Buen rendimiento en datos tabulares.
- Robusto ante valores faltantes.
- Compatible con SHAP para explicabilidad.

4. Optimización del modelo

Se utiliza Optuna para optimizar automáticamente hiperparámetros como:

- depth
- learning_rate
- iterations
- l2_leaf_reg

Objetivo: encontrar la configuración que maximiza el rendimiento predictivo.



MODELO RESULTADOS

CatBoost Classifier optimizado con Optuna

AUC de 0.671

Distingue correctamente entre pacientes con y sin reingreso aproximadamente el 67% de las veces, aunque todavía existe margen de mejora

Accuracy 74,8%

El modelo clasifica correctamente cerca de 3 de cada 4 pacientes. Sin embargo, en problemas médicos con clases desbalanceadas, la accuracy puede resultar engañosa, ya que un modelo puede acertar muchos casos de bajo riesgo y seguir detectando mal a los pacientes que realmente reingresan.

Recall 41,8%

El modelo identifica aproximadamente el 42% de los pacientes que realmente serán reingresados. Esto implica que todavía se escapan algunos pacientes de riesgo, pero se consigue detectar una parte importante de ellos para realizar intervenciones preventivas.

Precision 19,9%

De todos los pacientes clasificados como de alto riesgo, aproximadamente el 20% terminan reingresando realmente. Este valor relativamente bajo indica la existencia de falsos positivos, algo habitual en modelos clínicos cuyo objetivo principal es no dejar escapar pacientes de riesgo.

F1-Score 27%

El F1-Score refleja el equilibrio entre Precision y Recall. El valor obtenido muestra que el modelo prioriza la detección de pacientes en riesgo frente a la precisión de las alertas generadas, una estrategia habitual en aplicaciones sanitarias donde el coste de no detectar un paciente vulnerable puede ser elevado.

