

TFM MASTER DATA SCIENCE & IA EVOLVE ACADEMY

ASISTENTE CLÍNICO PARA LA PREDICCIÓN DE REINGRESOS HOSPITALARIOS EN PACIENTES CON DIABETES

AUTOR: CARLOS FORT DUART

ESTRUCTURA DEL PROYECTO

La estructura del proyecto se ha organizado de forma modular con el objetivo de facilitar el mantenimiento, la escalabilidad y la separación de responsabilidades.

La carpeta **assets** almacena recursos gráficos e imágenes utilizados por la interfaz. La carpeta **pages** contiene las distintas páginas o módulos de la aplicación Streamlit y la carpeta **reports** se utiliza para almacenar los informes PDF generados automáticamente.

El archivo principal **app.py** constituye el punto de entrada de la aplicación y coordina la interacción entre la interfaz, el modelo predictivo y el asistente de inteligencia artificial. Los archivos **modelo_diabetes_readmission.pkl**, **features.pkl**, **cat_features.pkl** y **best_threshold.pkl** almacenan el modelo entrenado y los objetos necesarios para realizar inferencias.

El fichero **diabetic_data.csv** es el fichero de datos original utilizado. Por su parte, **config.py** centraliza parámetros de configuración, mientras que los archivos de datos y pruebas se emplean para validación y desarrollo. Finalmente, **requirements.txt** recoge las dependencias necesarias para reproducir completamente el entorno de ejecución del proyecto.

MOTIVACIONES DEL ESTUDIO

1. Motivación clínica

La diabetes mellitus constituye una de las enfermedades crónicas con mayor prevalencia a nivel mundial y representa un importante desafío para los sistemas sanitarios. Los pacientes diabéticos suelen presentar múltiples comorbilidades asociadas, como enfermedades cardiovasculares, insuficiencia renal, hipertensión arterial o complicaciones metabólicas, que incrementan la probabilidad de hospitalización y reingreso hospitalario.

Los reingresos hospitalarios constituyen un indicador ampliamente utilizado para evaluar la calidad asistencial, ya que pueden reflejar problemas relacionados con el seguimiento clínico, la adherencia terapéutica, la complejidad del paciente o la transición entre la atención hospitalaria y la atención ambulatoria.

La identificación temprana de pacientes con elevado riesgo de reingreso permitiría implementar medidas preventivas específicas, optimizar el seguimiento tras el alta y mejorar los resultados clínicos obtenidos.

2. Motivación sanitaria

Los reingresos hospitalarios generan un importante impacto económico sobre los sistemas sanitarios debido al incremento de costes asistenciales asociados a nuevas hospitalizaciones, consultas médicas, pruebas diagnósticas y tratamientos.

Además del impacto económico, los reingresos se asocian con una peor calidad de vida para los pacientes, una mayor carga asistencial para los profesionales sanitarios y una utilización más intensiva de los recursos hospitalarios.

La capacidad de anticipar qué pacientes presentan una mayor probabilidad de reingreso permitiría una asignación más eficiente de los recursos sanitarios y facilitaría la implementación de programas específicos de seguimiento y prevención.

3. Motivación tecnológica

El crecimiento exponencial de los datos clínicos disponibles en los sistemas sanitarios ha impulsado el desarrollo de técnicas de Machine Learning capaces de identificar patrones complejos imposibles de detectar mediante métodos estadísticos tradicionales.

Los algoritmos de aprendizaje automático permiten analizar simultáneamente decenas de variables clínicas, administrativas y asistenciales para estimar probabilidades individuales de eventos clínicos futuros.

Asimismo, los avances recientes en Explainable Artificial Intelligence (XAI) permiten interpretar las decisiones de los modelos predictivos, aumentando la transparencia y facilitando su posible adopción en entornos clínicos reales.

PROBLEMA ABORDADO

El problema estudiado consiste en la predicción del riesgo de reingreso hospitalario en pacientes diabéticos utilizando información clínica y administrativa disponible durante los episodios asistenciales.

Desde una perspectiva de Machine Learning, se trata de un problema de clasificación binaria donde el objetivo es determinar si un paciente presenta o no un riesgo elevado de ser readmitido tras el alta hospitalaria.

La variable objetivo indica la existencia o ausencia de reingreso, mientras que las variables explicativas recogen información demográfica, clínica, diagnóstica, terapéutica y asistencial de cada paciente.

OBJETIVOS

Objetivo general

Desarrollar un modelo predictivo capaz de estimar la probabilidad de reingreso hospitalario en pacientes diabéticos mediante técnicas de Machine Learning e Inteligencia Artificial Explicable.

Objetivos específicos

- Analizar la información clínica disponible.
- Identificar factores asociados al reingreso hospitalario.
- Construir variables derivadas con relevancia clínica.
- Comparar diferentes algoritmos predictivos.
- Optimizar el modelo seleccionado mediante búsqueda automática de hiperparámetros.
- Evaluar el rendimiento utilizando múltiples métricas.
- Interpretar las predicciones mediante técnicas Explainable AI.
- Desplegar el modelo en una aplicación interactiva para usuarios finales.

PRODUCTO MÍNIMO VIABLE (MVP)

El MVP desarrollado consiste en un sistema capaz de:

- Recibir información clínica de un paciente.
- Calcular automáticamente la probabilidad de reingreso.
- Clasificar al paciente según su nivel de riesgo.
- Explicar las variables que más han influido en la predicción.
- Generar recomendaciones clínicas básicas.
- Facilitar la interpretación de resultados por parte del usuario.

Este MVP constituye la base sobre la que posteriormente se construirá la aplicación interactiva desarrollada en la Parte II del proyecto.

PARTE I. DESARROLLO DEL MODELO PREDICTIVO DE REINGRESO HOSPITALARIO EN PACIENTES DIABÉTICOS

1. Descripción del conjunto de datos

El conjunto de datos utilizado contiene información histórica de pacientes diabéticos hospitalizados, obtenido de Kaggle [Diabetes 130 US hospitals for years 1999-2008](#)

Las variables disponibles pueden clasificarse en varios grupos.

Variables cualitativas

- Demográficas (race, gender, age)
- Clínicas (medical_specialty, diag_1_group, diag_2_group, diag_3_group)
- Control metabólico (max_glu_serum, A1Cresult)
- Tratamiento farmacológico (diabetesMed, insulin, metformin, glipizide, glyburide, pioglitazone, rosiglitazone, resto de medicamentos antidiabéticos)

Variables cuantitativas

- Utilización sanitaria (time_in_hospital, num_lab_procedures, num_procedures, num_medications, number_outpatient, number_emergency, number_inpatient, number_diagnoses)

2. Análisis exploratorio de datos (EDA)

Hemos realizado un análisis exploratorio completo con el objetivo de comprender la estructura del conjunto de datos y detectar posibles problemas de calidad.

Las principales tareas realizadas han sido:

Análisis de valores perdidos

Identificamos variables con un elevado porcentaje de valores desconocidos (weight, payer_code, medical_specialty). Aplicamos estrategias específicas de tratamiento para minimizar la pérdida de información.

Distribución de variables

Analizamos histogramas, diagramas de barras y estadísticas descriptivas para estudiar la distribución de las variables numéricas y categóricas.

Estudio de la variable objetivo

Observamos un importante desbalanceo entre clases, siendo significativamente más frecuentes los pacientes sin reingreso que aquellos que experimentaban una nueva hospitalización. Este aspecto condicionó la estrategia posterior de evaluación del modelo.

Relaciones entre variables

Se exploraron asociaciones entre variables clínicas y la variable objetivo mediante análisis descriptivos y visualizaciones específicas.

3. Ingeniería de características (Feature Engineering)

Con el objetivo de incrementar la capacidad predictiva del modelo se construyeron nuevas variables derivadas con significado clínico.

clinical_complexity

Representa la complejidad global del paciente:

$\text{clinical_complexity} = \text{num_medications} + \text{number_diagnoses}$

previous_utilization

Mide la utilización previa del sistema sanitario:

$\text{previous_utilization} = \text{number_inpatient} + \text{number_outpatient} + \text{number_emergency}$

medication_load

Refleja simultáneamente polimedicación y multimorbilidad:

$\text{medication_load} = \text{num_medications} \times \text{number_diagnoses}$

medication_per_day

Intensidad terapéutica diaria.

lab_per_day

Intensidad diagnóstica diaria.

diagnoses_per_day

Densidad diagnóstica durante el ingreso.

polypharmacy

Variable binaria que identifica pacientes con polimedicación.

elderly

Variable binaria para pacientes de edad avanzada.

high_utilization

Identifica pacientes con utilización sanitaria intensa.

multiple_admissions

Identifica pacientes con múltiples hospitalizaciones.

high_risk_history

Representa antecedentes clínicos de elevado riesgo.

very_complex

Identifica pacientes con elevada complejidad diagnóstica.

4. Construcción del modelo predictivo

División del conjunto de datos

Los datos fueron divididos en: *Training Set* (Utilizado para el aprendizaje del modelo), *Validation Set* (Utilizado durante la optimización de hiperparámetros) y *Test Set* (Reservado para la evaluación final y completamente independiente del entrenamiento). Esta estrategia permite estimar adecuadamente la capacidad de generalización del modelo.

5. Selección del algoritmo

Se seleccionó CatBoost Classifier debido a varias ventajas:

- Excelente rendimiento en datos tabulares.
- Tratamiento nativo de variables categóricas.
- Menor necesidad de preprocesamiento.
- Robustez frente a valores faltantes.
- Elevada capacidad predictiva.
- Compatibilidad con técnicas Explainable AI.

6. Optimización mediante Optuna

La optimización de hiperparámetros se realizó mediante Optuna.

Optuna utiliza estrategias de búsqueda inteligente que permiten explorar automáticamente múltiples configuraciones del modelo.

Entre los hiperparámetros optimizados se incluyeron: *depth*, *learning_rate*, *iterations*, *l2_leaf_reg*, *random_strength* y *bagging_temperature*. El objetivo fue maximizar la capacidad discriminativa del modelo manteniendo una adecuada generalización.

7. Evaluación del modelo

Accuracy = 0.748

Indica que aproximadamente el 74.8% de las observaciones fueron clasificadas correctamente. Sin embargo, debido al desbalanceo de clases, esta métrica debe interpretarse con cautela.

AUC = 0.671

Mide la capacidad discriminativa global del modelo. Un valor de 0.671 indica una capacidad moderada para distinguir entre pacientes que serán readmitidos y pacientes que no serán readmitidos.

Recall = 0.418

Representa la proporción de pacientes realmente readmitidos que el modelo consigue identificar correctamente. Desde una perspectiva clínica, esta métrica

resulta especialmente relevante, ya que refleja la capacidad para detectar pacientes de riesgo.

Precision = 0.199

Indica la proporción de pacientes clasificados como de alto riesgo que realmente experimentan un reingreso. El valor relativamente reducido está asociado al importante desbalanceo existente en el conjunto de datos.

F1 Score = 0.270

Combina precisión y recall en una única métrica, proporcionando una visión equilibrada del rendimiento del modelo.

8. Interpretabilidad mediante SHAP

Para aumentar la transparencia del sistema se empleó SHAP (SHapley Additive Explanations). SHAP permite cuantificar la contribución individual de cada variable a una predicción concreta.

Las variables con mayor influencia identificadas fueron:

- Ingresos hospitalarios previos.
- Utilización previa del sistema sanitario.
- Historial clínico de riesgo.
- Complejidad clínica.
- HbA1c.
- Carga farmacológica.

Gracias a SHAP fue posible interpretar las decisiones del modelo y justificar clínicamente cada predicción individual.

9. Conclusiones de la Parte I

El modelo desarrollado demuestra que es posible estimar el riesgo de reingreso hospitalario en pacientes diabéticos utilizando técnicas modernas de Machine Learning.

La combinación de CatBoost, Optuna y SHAP permitió obtener un sistema con capacidad predictiva razonable y, al mismo tiempo, interpretable para profesionales sanitarios.

Los resultados obtenidos justifican la construcción de una aplicación interactiva que permita utilizar el modelo en un entorno más cercano a la práctica clínica real, aspecto desarrollado en la Parte II del proyecto.

PARTE II. DESARROLLO DE UNA APLICACIÓN INTELIGENTE DE APOYO A LA DECISIÓN CLÍNICA

1. Justificación de la aplicación web

La construcción de un modelo predictivo constituye únicamente una parte del proceso de generación de valor mediante Inteligencia Artificial. Aunque el modelo desarrollado en la Parte I es capaz de estimar el riesgo de reingreso hospitalario en pacientes diabéticos, su utilización práctica resulta limitada si únicamente se encuentra disponible en forma de notebook o script de Python.

En entornos clínicos reales, los profesionales sanitarios necesitan herramientas accesibles, intuitivas y capaces de proporcionar resultados interpretables sin necesidad de conocimientos técnicos avanzados.

Por este motivo, se decidió desarrollar una aplicación web interactiva utilizando Streamlit, una tecnología especialmente diseñada para desplegar modelos de Machine Learning de forma rápida, visual y accesible.

La aplicación permite transformar un modelo predictivo complejo en una herramienta fácilmente utilizable por profesionales sanitarios, investigadores o gestores hospitalarios.

2. Objetivos de la aplicación

La aplicación desarrollada persigue los siguientes objetivos:

- Facilitar la introducción de información clínica relevante.
- Estimar automáticamente el riesgo de reingreso hospitalario.
- Mostrar resultados de forma visual e intuitiva.
- Explicar las predicciones mediante técnicas de Inteligencia Artificial Explicable.
- Generar informes clínicos automáticos.
- Incorporar un asistente conversacional basado en Inteligencia Artificial.
- Mejorar la interpretabilidad y utilidad práctica del modelo predictivo.

3. Arquitectura general del sistema

La aplicación se estructura en cuatro módulos principales:

Módulo 1: Predicción

Permite introducir los datos clínicos del paciente y obtener la probabilidad de reingreso.

Módulo 2: Informe clínico

Genera automáticamente un informe textual resumido de los resultados obtenidos.

Módulo 3: Asistente de Inteligencia Artificial

Permite realizar preguntas en lenguaje natural sobre el caso clínico analizado.

Módulo 4: Información del modelo

Presenta información técnica sobre el algoritmo utilizado y sus métricas de rendimiento.

4. Diseño del formulario clínico

Selección de variables

Aunque el modelo original fue entrenado utilizando más de sesenta variables clínicas y administrativas, se decidió solicitar al usuario únicamente aquellas variables con mayor relevancia clínica y mayor capacidad explicativa.

Las variables incluidas en el formulario fueron:

- Variables demográficas (Edad, Sexo y Raza)
- Variables asistenciales (Días de hospitalización, Número de ingresos previos, Número de consultas externas y Número de visitas a urgencias)
- Variables clínicas (Número de diagnósticos, Número de medicamentos y Número de pruebas de laboratorio)
- Variables metabólicas (Resultado de HbA1c y Nivel máximo de glucosa)

Justificación de la reducción de variables

Solicitar las más de sesenta variables originales habría generado una interfaz excesivamente compleja y poco práctica.

Además, muchas variables presentan un bajo impacto individual sobre la predicción o contienen información redundante.

La selección realizada busca un equilibrio entre:

- Simplicidad de uso.
- Rapidez de introducción de datos.
- Capacidad predictiva.
- Interpretabilidad clínica.

El resto de variables necesarias para el modelo son generadas automáticamente mediante reglas predefinidas o valores clínicamente razonables.

5. Generación automática de variables derivadas

A partir de los datos introducidos por el usuario, la aplicación reconstruye automáticamente todas las variables derivadas utilizadas durante el entrenamiento.

Entre ellas destacan:

- clinical_complexity
- previous_utilization
- medication_load
- medication_per_day
- lab_per_day
- diagnoses_per_day
- polypharmacy
- elderly
- high_utilization
- multiple_admissions
- high_risk_history
- very_complex

Esta estrategia garantiza que las características utilizadas durante la fase de entrenamiento sean reproducidas de forma consistente durante la inferencia.

6. Sistema de clasificación del riesgo

El modelo genera inicialmente una probabilidad continua de reingreso comprendida entre 0 y 1. Sin embargo, para facilitar la interpretación clínica, se definieron categorías de riesgo basadas en el umbral óptimo obtenido durante la fase de validación.

Riesgo bajo

Probabilidad inferior al 30%.

Riesgo intermedio

Probabilidad comprendida entre el 30% y el umbral óptimo del modelo.

Riesgo alto

Probabilidad superior al umbral óptimo de clasificación.

La clasificación final mostrada al usuario corresponde al resultado obtenido tras aplicar dicho threshold optimizado.

7. Visualización de resultados

Los resultados se presentan mediante diferentes elementos visuales.

Métricas principales

La aplicación muestra:

- Probabilidad estimada.
- Clasificación obtenida.
- Threshold utilizado.

Velocímetro clínico

Se implementó un indicador visual tipo gauge mediante Plotly. Este velocímetro permite identificar rápidamente la posición del paciente respecto al umbral de riesgo

establecido. Las zonas de color se encuentran alineadas con los criterios de clasificación utilizados por el modelo.

8. Interpretabilidad mediante SHAP

Uno de los principales objetivos de la aplicación consiste en evitar que el modelo funcione como una caja negra. Para ello se incorporó SHAP (SHapley Additive Explanations), una técnica ampliamente utilizada en Explainable AI. SHAP permite calcular la contribución individual de cada variable a una predicción concreta.

La aplicación muestra:

- Variables que incrementan el riesgo.
- Variables que reducen el riesgo.
- Magnitud del impacto de cada factor.

Además, se incorpora una representación gráfica de los principales factores explicativos. Gracias a este enfoque, los usuarios pueden comprender por qué el modelo ha generado una determinada predicción.

9. Generación automática de recomendaciones clínicas

La aplicación incorpora un sistema automático de recomendaciones basado en reglas clínicas sencillas. Estas recomendaciones se generan a partir de:

- Número de ingresos previos.
- Polimedicación.
- Complejidad clínica.
- Duración de la hospitalización.

Posteriormente, dichas recomendaciones son enriquecidas utilizando los factores más relevantes identificados mediante SHAP. Este enfoque híbrido combina conocimiento clínico explícito con interpretabilidad basada en Machine Learning.

10. Generación automática de informes

Con el objetivo de facilitar la documentación clínica, se desarrolló un sistema de generación automática de informes. El informe incluye:

- Probabilidad estimada de reingreso.
- Clasificación obtenida.
- Factores más relevantes.
- Recomendaciones clínicas.

El documento puede visualizarse directamente desde la aplicación y descargarse en formato PDF. Esta funcionalidad permite transformar los resultados del modelo en documentación fácilmente compartible.

11. Integración de Inteligencia Artificial Generativa

La simple visualización de métricas y gráficos puede resultar insuficiente para determinados usuarios. Por este motivo se incorporó un asistente conversacional basado en Large Language Models (LLM), capaz de responder preguntas en lenguaje natural sobre cada caso clínico.

12. Elección de Ollama

Se seleccionó Ollama como plataforma de inferencia local por diversas razones:

- Ejecución completamente local.
- Ausencia de costes por uso.
- Protección de la privacidad de los datos.
- Facilidad de integración con Python.
- Compatibilidad con modelos modernos de lenguaje.

La ejecución local evita el envío de información clínica a servicios externos y mejora la confidencialidad de los datos procesados.

13. Modelo de lenguaje utilizado

Se empleó el modelo: Llama 3.2 3B

Este modelo ofrece una relación adecuada entre:

- Calidad de respuesta.
- Velocidad de inferencia.
- Consumo de recursos.

Resulta especialmente adecuado para aplicaciones académicas y prototipos clínicos.

14. Diseño del prompt clínico

El asistente no responde únicamente a partir de la pregunta del usuario. Antes de generar una respuesta recibe:

Información clínica

- Edad.
- Ingresos previos.
- Urgencias.
- Diagnósticos.
- Medicación.
- HbA1c.
- Glucosa máxima.

Resultado predictivo

- Probabilidad de reingreso.

- Clasificación obtenida.

Explicabilidad

- Factores SHAP.
- Impacto positivo o negativo de cada variable.

Recomendaciones clínicas

- Recomendaciones generadas automáticamente por la aplicación.

Además, se incorporaron instrucciones específicas para:

- No recalcular el riesgo.
- Mantener la clasificación oficial del modelo.
- Responder en español.
- No sustituir al médico.
- Generar respuestas breves y estructuradas.

15. Resultados obtenidos

La aplicación desarrollada permite transformar un modelo predictivo complejo en una herramienta interactiva capaz de:

- Realizar predicciones individuales.
- Explicar cada decisión tomada por el modelo.
- Generar documentación clínica automática.
- Facilitar la interacción mediante lenguaje natural.

La combinación de Machine Learning, Explainable AI y modelos generativos permite ofrecer una experiencia significativamente más cercana a las necesidades reales de los usuarios finales.

16. Conclusiones de la Parte II

La aplicación desarrollada demuestra que es posible integrar modelos predictivos, técnicas de Inteligencia Artificial Explicable y modelos generativos dentro de una única plataforma interactiva. El resultado final no consiste únicamente en un clasificador de riesgo, sino en un sistema inteligente de apoyo a la decisión clínica capaz de proporcionar predicciones, explicaciones, recomendaciones e interacción conversacional. Esta aproximación incrementa la interpretabilidad, accesibilidad y utilidad práctica de los modelos de Machine Learning en el ámbito sanitario.

LIMITACIONES Y FUTURAS AMPLIACIONES

Limitaciones

Aunque los resultados obtenidos son satisfactorios, el presente trabajo presenta diversas limitaciones. En primer lugar, el rendimiento predictivo alcanzado es moderado ($AUC = 0.67$), lo que indica que existe margen de mejora en la capacidad de discriminación del modelo. Además, el conjunto de datos utilizado procede de un contexto clínico específico, por lo que la capacidad de generalización a otros hospitales o sistemas sanitarios podría verse limitada.

Por otra parte, la aplicación solicita únicamente un subconjunto de las variables empleadas durante el entrenamiento, utilizando valores por defecto para determinadas características clínicas. Esta simplificación mejora la usabilidad de la herramienta, aunque puede reducir ligeramente la precisión de las predicciones individuales.

Finalmente, las respuestas generadas por el asistente basado en modelos de lenguaje tienen carácter informativo y de apoyo a la interpretación, sin sustituir en ningún caso el criterio clínico profesional.

Futuras ampliaciones

Como líneas futuras de desarrollo, sería interesante incorporar nuevos conjuntos de datos procedentes de diferentes centros hospitalarios para mejorar la robustez y capacidad de generalización del modelo. Asimismo, podrían integrarse variables clínicas adicionales obtenidas directamente de historias clínicas electrónicas, reduciendo la necesidad de introducción manual de información.

Desde el punto de vista tecnológico, se podría desplegar la aplicación en la nube para facilitar su acceso remoto, así como incorporar mecanismos de autenticación y gestión segura de usuarios. También resultaría de gran interés ampliar las capacidades del asistente conversacional mediante modelos de lenguaje más avanzados y técnicas de recuperación de conocimiento clínico especializado (RAG), permitiendo respuestas más precisas y contextualizadas.

Finalmente, una posible evolución del proyecto consistiría en realizar una validación prospectiva en un entorno clínico real, evaluando el impacto de la herramienta sobre la toma de decisiones y la reducción efectiva de los reingresos hospitalarios.